

# VERİ BİLİMİ DERSİ PROJE RAPORU

**Proje Başlığı:** E-Ticaret Verilerinde RFM Metrikleri ile K-Means Kümeleme Tabanlı Müşteri Segmentasyonu ve Davranış Analizi

## 1. PROBLEM TANIMI

Günümüz e-ticaret sektöründe rekabet avantajı elde etmek, müşteri sadakatini artırmak ve pazarlama bütçelerini optimize etmek için müşteri tabanının homojen gruplara ayrılması (segmentasyon) kritik bir öneme sahiptir. Her müşteriye aynı pazarlama stratejisiyle yaklaşmak; hem kaynak israfına hem de müşteri kaybına (churn) yol açmaktadır. Bu projenin problemi; geniş bir müşteri veri tabanındaki bireysel satın alma alışkanlıklarının analiz edilerek, operasyonel süreçleri iyileştirecek ve hedeflenmiş pazarlama stratejilerine (makro ve mikro kampanyalar) zemin hazırlayacak anlamlı müşteri profillerinin yapay zeka ve makine öğrenmesi algoritmalarıyla otomatik olarak nasıl oluşturulabileceğidir.

## 2. KULLANILAN VERİ SETİ VE KAYNAĞI

Projede, İngiltere merkezli ve hediyelik eşya satışı yapan tescilli bir çevrimiçi perakende şirketinin 01/12/2010 ile 09/12/2011 tarihleri arasındaki gerçek işlemlerini içeren "**Online Retail**" veri seti kullanılmıştır. Veri setine [kagglehub](https://www.kaggle.com/datasets/online-retail) kütüphanesi aracılığıyla doğrudan Kaggle Açık Veri Portalı üzerindeki "tunguz/online-retail" adresinden erişilmiştir. Veri seti ham halinde 541.909 satır ve 8 sütundan oluşmaktadır. Özniteliklerin yapısal tanımları şu şekildedir:

- InvoiceNo** : Her işleme atanan 6 haneli benzersiz fatura numarası (İptaller 'C' ile başlar).
- StockCode** : Her benzersiz ürne atanan 5 haneli ürün kodu.
- Description** : Ürün adı veya açıklaması.
- Quantity** : İşlem başına sipariş edilen ürün adedi.
- InvoiceDate** : İşlemin gerçekleştiği gün ve saat.
- UnitPrice** : Sterlin (£) cinsinden ürün birim fiyatı.
- CustomerID** : Her müşteriye atanan 5 haneli benzersiz müşteri numarası.
- Country** : Müşterinin yaşadığı ülke.

## 3. YÖNTEM (VERİ BİLİMİ İŞ AKIŞI)

Projede uçtan uca eksiksiz bir veri bilimi iş akışı izlenmiştir:

### 3.1. Veri Ön İşleme ve Temizleme

Ham veri setindeki gürültüleri temizlemek adına şu adımlar uygulanmıştır:

- Eksik Veri Yönetimi:** Doldurulması istatistiksel olarak mümkün olmayan ve modellemeyi doğrudan bozacak olan **CustomerID** sütunundaki boş satırlar veri setinden elenmiştir.
- Veri Tipi Dönüşümü:** **InvoiceDate** sütunu metin formatından **datetime** nesnesine dönüştürülmüştür.
- Hatalı ve İptal Kayıtların Elenmesi:** Fatura numarasında 'C' (Cancellation) bulunan iade işlemleri sistemsel olarak filtrelenmiştir. Ayrıca **Quantity** ve **UnitPrice** sütunlarında yer alan sıfır veya negatif (hatalı girilmiş) değerler ayrılmıştır. Temizlik sonucunda 397.884 adet geçerli satır kalmıştır.

### 3.2. Özellik Mühendisliği (Feature Engineering)

Analiz ve modelleme aşaması öncesinde ham verilerden yeni metrikler türetilmiştir:

- **TotalAmount** : Satış miktar ve birim fiyatı çarpılarak toplam harcama tutarı hesaplanmıştır.
- **Hour** ve **DayOfWeek** : Zamansal trendleri görmek adına fatura tarihinden işlem saati ve gün isimleri ayrıştırılmıştır.

### 3.3. RFM Metriklerinin Çıkarılması ve Standartlaştırma

K-Means kümeleme modeline girdi sağlamak üzere müşteri bazında üç temel davranışsal öznelik (RFM) hesaplanmıştır:

- **Recency (Yenilik)**: Müşterinin veri setindeki en son tarihten bu yana yaptığı son alışveriş üzerinden geçen gün sayısı.
  - **Frequency (Sıklık)**: Müşterinin yaptığı toplam benzersiz alışveriş (fatura) sayısı.
  - **Monetary (Parasal Değer)**: Müşterinin şirket bünyesinde yaptığı toplam harcama tutarı.
- K-Means algoritması mesafe tabanlı (Euclidean) çalıştığı ve varyansa duyarlı olduğu için, bu üç metrik **StandardScaler** kullanılarak ortalaması 0, standart sapması 1 olacak şekilde standartlaştırılmıştır.


### 3.4. K-Means Modellemesi

En uygun küme sayısını (k) belirlemek amacıyla **Dırsek Yöntemi (Elbow Method)** uygulanmıştır. WCSS (küme içi kareler toplamı) değerlerinin bükülme noktası incelenerek optimum küme sayısı k=4 olarak seçilmiş ve model eğitilmiştir.

## 4. BULGULAR VE KEŞİFSEL VERİ ANALİZİ (EDA)

### 4.1. Ürün Bazlı Finansal Dağılım


Yapılan gruplama sonucunda şirkete en yüksek finansal getiriye sağlayan ürünler analiz edilmiştir.



Yukarıdaki görsel incelendiğinde, platformda en yüksek ciroyu "PAPER CRAFT , LITTLE BIRDIE" ve "REGENCY CAKESTAND 3 TIER" isimli ürünlerin getirdiği açıkça görülmektedir. Bu bilgi, stok yönetiminde ve tedarik zinciri planlamasında önceliklendirilmesi gereken amiral gemisi ürünleri doğrulamaktadır.

### 4.2. Sipariş Tutarlarının Dağılım Yapısı


Sipariş bazında harcama tutarlarının nasıl bir yoğunluğa sahip olduğu histogram yardımıyla incelenmiştir.



Grafik üzerinde görüldüğü üzere, harcama tutarları sağa çarpık bir dağılım sergilemekle birlikte, 100-200 £ ve 300 £ civarında belirgin iki tepe noktası (bimodal dağılım) oluşturmaktadır. Bu durum, kullanıcıların belirli sepet ortalamalarına eğilimli olduğunu ve bu eşiklerin altına özel kargo veya kupon kampanyaları kurgulanabileceğini göstermektedir.

#### 4.3. Zamansal Sipariş Yoğunluğu


Müşterilerin gün ve saat bazında satın alma eğilimleri matris tabanlı bir ısı haritası ile ortaya konmuştur.



Isı haritası verilerine göre, siparişlerin ağırlıklı olarak hafta içi günlerde ve özellikle saat 10:00 ile 15:00 arasında (özellikle saat 12:00 civarında pik yapacak şekilde) yoğunlaştığı tespit edilmiştir. Cumartesi günleri sistemde hiç kayıt olmaması dikkat çekicidir. Bu bulgu, sunucu yükü optimizasyonu, canlı destek personeli planlaması ve pazarlama e-postalarının gönderim zamanlaması için doğrudan bir kılavuz niteliğindedir.

#### 4.4. K-Means Modelleme ve Segmentasyon Sonuçları

Hiperparametre optimizasyonunun ardından eğitilen K-Means modeli, müşteri tabanını net matematiksel sınırlarla 4 farklı sınıfa ayırmıştır.



Yukarıda verilen logaritmik dağılım grafiğinde modelin müşterileri harcama ve sıklık boyutlarında nasıl başarıyla kümelediği görülmektedir. Küme ortalamalarına dayanarak yapılan iş zekası yorumları şu şekildedir:

- **Cluster 2 - Şampiyonlar (Yeşil Noktalar):** Alışveriş sıklığı çok yüksek (ortalama 82 fatura) ve kişi başı ortalama 127.338 £ gibi devasa ciro bırakan, sistemin en değerli VIP kitlesidir. Özel sadakat programları uygulanmalıdır.
- **Cluster 3 - Sadık Müşteriler (Mor Noktalar):** Son alışveriş zamanı yakın (ortalama 15 gün), ciro getirisi (ortalama 12.709 £) ve sürekliliği yüksek olan ana gelir motorudur.
- **Cluster 0 - Yeni / Potansiyel Müşteriler (Kırmızı Noktalar):** Alışveriş sıklığı düşük, ciro getirisi standart düzeyde (ortalama 1.359 £) olan ve yakın zamanda sisteme dahil olmuş gruptur. Doğru çapraz satış (cross-sell) stratejileriyle Cluster 3'e taşınmalıdır.
- **Cluster 1 - Kaybedilen / Uykudaki Müşteriler (Mavi Noktalar):** Son satın almasının üzerinden ortalama 248 gün geçmiş, platformu terk etme eğiliminde olan düşük cirolu kitledir. Agresif "Geri Kazanma" (Win-back) kampanyaları hedefi olmalıdırlar.

## 5. SINIRLAMALAR

Projenin yürütülmesi ve sonuçların yorumlanması aşamasındaki temel sınırlamalar şunlardır:

- **Mekansal Kısıt:** Veri seti ezici bir çoğunlukla Birleşik Krallık (UK) tabanlı işlemler içerdüğinden, elde edilen zaman ve saat yoğunlukları coğrafi ve kültürel olarak sadece bu bölgeyi yansıtmaktadır; küresel bir müşteri genellemesi yapılamaz.
- **Veri Eksikliği:** Orijinal verideki satırların yaklaşık %25'inde **CustomerID** bilgisi eksik olduğu için bu satırlar analiz dışı bırakılmıştır. Bu durum ciro tahminlerinde genel bir alt sınıra yol açmış olabilir.
- **Model Sınırları:** K-Means modeli doğrusal olmayan karmaşık ilişkileri yakalamakta zorlanabilir ve başlangıç merkez noktalarına (centroid) duyarlıdır. Ayrıca kapsam dar tutulduğu için derinlemesine hiperparametre optimizasyonu yapılmamıştır.

## 6. ÖĞRENİLENLER VE SONUÇ

Bu dönem projesi kapsamında, gerçek dünya e-ticaret verilerinin ham halinden başlanarak temizlenmesi, yapılandırılması, anlamlı iş sorularına yanıt arayacak şekilde görselleştirilmesi ve nihayetinde makine öğrenmesi algoritmalarıyla segmentasyonu aşamaları başarıyla deneyimlenmiştir.

"Vibe coding" yaklaşımla bir yapay zeka asistanını birincil geliştirme ortağı olarak kullanmak; kod yazım hızını ciddi ölçüde artırırken, mimariyi kurma, çıkan sonuçları doğrulama, uyarılara müdahale etme ve matematiksel çıktıları ticari/akademik bir dille yorumlama süreçlerinde veri bilimcinin "yönlendirici ve doğrulayıcı" rolünün ne kadar kritik olduğunu göstermiştir. K-Means algoritmasının RFM analiziyle birleştğinde müşteri davranışlarını segmentlere ayırmada ne kadar güçlü ve savunulabilir bir araç olduğu uygulamalı olarak öğrenilmiştir.